Open Competition Kaggle

서주원

0. 데이터 설명

PassengerID	승객 번호
Survived	생존여부(1:생존, 0:사망)
Pclass	승선권 클래스(1: 1st, 2: 2nd, 3: 3rd)
Name	승객 이름
Sex	승객 성별
Age	승객 나이
SibSp	동반한 형제자매, 배우자 수
Patch	동반한 부모, 자식 수
Ticket	티켓의 고유 넘버
Fare	티켓의 요금
Cabin	객실 번호
Embarked	승선한 항구 명(C: Cherbourg, Q: Queenstown, S: Southampton)

다음과 같은 12개의 속성을 가진 데이터를 이용해서 모델을 학습합니다.

학습한 모델을 가지고 PassengerID가 주어졌을 때, 해당 승객의 생존여부를 예측하는 대회입니다.

1. 준비

```
In [1]: import numpy as np
        import pandas as pd
        import re
        import matplotlib.pyplot as plt
        import seaborn as sns
        sns.set()

        from xgboost import XGBClassifier

        from sklearn.linear_model import LogisticRegression
        from sklearn.metrics import accuracy_score, confusion_matrix
        from sklearn import utils
        from sklearn import preprocessing
        from sklearn.model_selection import train_test_split
        from sklearn.ensemble import RandomForestClassifier, AdaBoostClassifier, GradientBoostingClassifier, ExtraTreesClassifier
        from sklearn.ensemble import VotingClassifier
        from sklearn.tree import DecisionTreeClassifier
        from sklearn.svm import SVC
        from sklearn.model_selection import KFold, StratifiedKFold, cross_val_score, cross_val_predict,GridSearchCV
```

- 개인 pc의 anaconda, jupyter notebook을 이용했습니다.

2. 데이터 로드

```
In [2]: # 1. data load
        # train data load
        # 12개의 속성을 가지고 있다.
        train = pd.read_csv("titanic/train.csv")
        train.head()
```

Out[2]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

```
In [3]: # test data load
        # 11개의 속성을 가지고 있다.(train에서 생존여부 속성 제외)
        test = pd.read_csv("titanic/test.csv")
        test.head()
```

Out[3]:

	PassengerId	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	892	3	Kelly, Mr. James	male	34.5	0	0	330911	7.8292	NaN	Q
1	893	3	Wilkes, Mrs. James (Ellen Needs)	female	47.0	1	0	363272	7.0000	NaN	S
2	894	2	Myles, Mr. Thomas Francis	male	62.0	0	0	240276	9.6875	NaN	Q
3	895	3	Wirz, Mr. Albert	male	27.0	0	0	315154	8.6625	NaN	S
4	896	3	Hirvonen, Mrs. Alexander (Helga E Lindqvist)	female	22.0	1	1	3101298	12.2875	NaN	S

- train.csv를 가져온 data입니다. training에 이용되는 data들은 12개의 속성을 가지고 있습니다.

- test.csv를 가져온 data입니다. Survived 속성이 제외된 11개의 속성을 가지고 있습니다.

```
In [4]: sub = test['PassengerId']
```

- 데이터 preprocessing 과정에서 test dataframe에서 'PassengerId'속성을 제거하기 때문에 submission을 위해서 미리 데이터를 추출합니다.

3. 데이터 분석

In [5]:
```
# # 2.  data analysis
# 해당 함수는 feature를 input으로 넣었을 때, 생존자와 사망자의 비율을 보여준다.
# 속성 분석을 통해서 생존여부에 영향을 끼치는 속성을 골라낼 수 있다.

def bar_chart(feature):
    survived = train[train['Survived']==1][feature].value_counts() # feature에서 생존한 인원수
    dead = train[train['Survived']==0][feature].value_counts() # feature에서 사망한 인원수
    df = pd.DataFrame([survived, dead])
    df.index = ['Survived','Dead']
    df.plot(kind='bar', stacked=True, figsize=(10,5))
```

(1) 'Sex'

In [6]:
```
# 1) sex
# 성별을 보면 여자가 남자보다 훨씬 많은 비율로 생존함을 볼 수 있다.
# sex 속성은 생존여부를 파악하는데 중요한 요소다.

train['Survived'].groupby(train['Sex']).mean()
```

Out[6]:
```
Sex
female    0.742038
male      0.188908
Name: Survived, dtype: float64
```

In [7]:
```
# 남자의 경우 많은 수가 사망했다는 사실을 알 수 있다.

bar_chart('Sex')
```

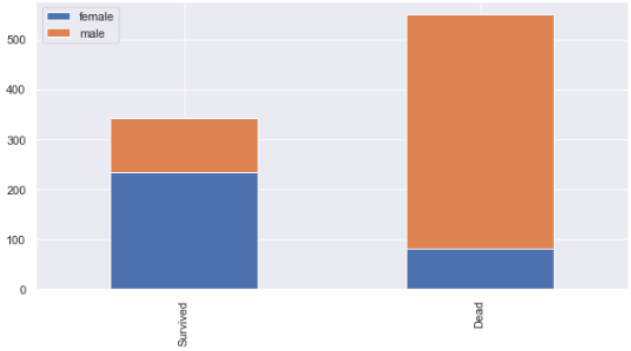

(2) 'Pclass'

In [8]:
```
# 2) Pclass
# 생존자 중 Pclass가 1인 사람이 많다
# class가 내려갈 수록 생존비율이 20%씩 줄어든다.

train['Survived'].groupby(train['Pclass']).mean()
```

Out[8]:
```
Pclass
1    0.629630
2    0.472826
3    0.242363
Name: Survived, dtype: float64
```

In [9]:
```
# 확실하게 pclass=3일 때, 사망자가 많은 것을 볼 수 있다.

bar_chart('Pclass')
```

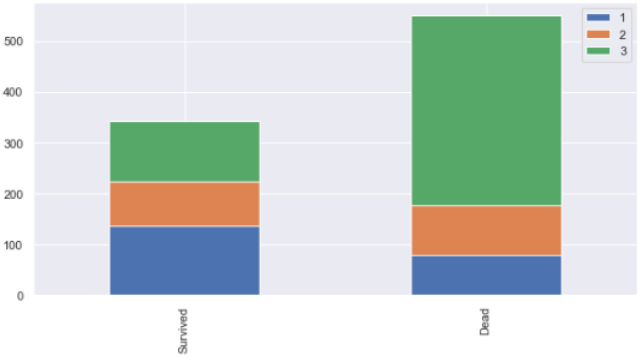

(3) 'Embarked'

In [10]:
```
# 3) Embarked
# 탑승항구가 S인 사람이 제일 많았다.
# 또한 C 항구에서 탑승했을 때가 생존비율이 제일 높다.

print(train['Embarked'].value_counts(normalize=True))
print("----------------------------------------")
print(train['Survived'].groupby(train['Embarked']).mean())
```

```
S    0.724409
C    0.188976
Q    0.086614
Name: Embarked, dtype: float64
----------------------------------------
Embarked
C    0.553571
Q    0.389610
S    0.336957
Name: Survived, dtype: float64
```

In [11]:
```
# S 항구에서 탑승한 승객이 사망률이 제일 높다.

bar_chart('Embarked')
```

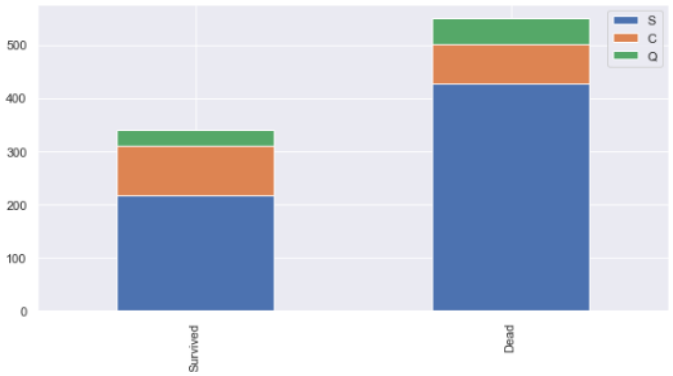

(4) 'SibSp'

In [12]:
```
# 4) SibSp
# 형제자매가 5명, 8명인 경우에는 모두 사망했다.
# 형제자매가 1-2명일 때가 생존비율이 높다.

print(train['Survived'].groupby(train['SibSp']).mean())
print('--------------------------------')
print(train['SibSp'].value_counts())
```

```
SibSp
0    0.345395
1    0.535885
2    0.464286
3    0.250000
4    0.166667
5    0.000000
8    0.000000
Name: Survived, dtype: float64
--------------------------------
0    608
1    209
2     28
4     18
3     16
8      7
5      5
Name: SibSp, dtype: int64
```

In [13]:
```
# 형제 자매 없이 혼자 탔을 경우 사망자가 제일 많았다.
# 동시에 생존자도 제일 많다.

bar_chart('SibSp')
```

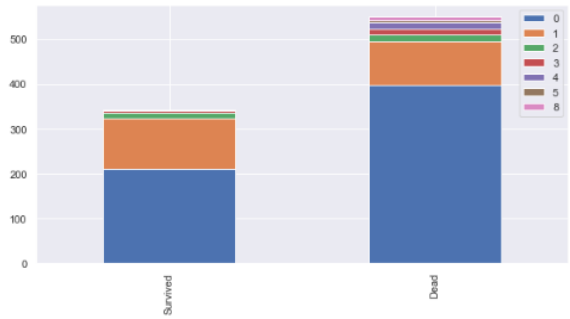

(5) 'Parch'

In [14]:
```
# 5) Parch
# 부모, 자식이 4명, 6명일 경우 모두 사망했다.
# 부모, 자식이 1-3명인 경우 생존비율이 높았다.

print(train['Survived'].groupby(train['Parch']).mean())
print('--------------------------------')
print(train['Parch'].value_counts())
```

```
Parch
0    0.343658
1    0.550847
2    0.500000
3    0.600000
4    0.000000
5    0.200000
6    0.000000
Name: Survived, dtype: float64
--------------------------------
0    678
1    118
2     80
5      5
3      5
4      4
6      1
Name: Parch, dtype: int64
```

In [15]:
```
# Sibsp 속성과 마찬가지로 혼자 탑승한 승객인 사망자도 생존자도 적을 것다.

bar_chart('Parch')
```

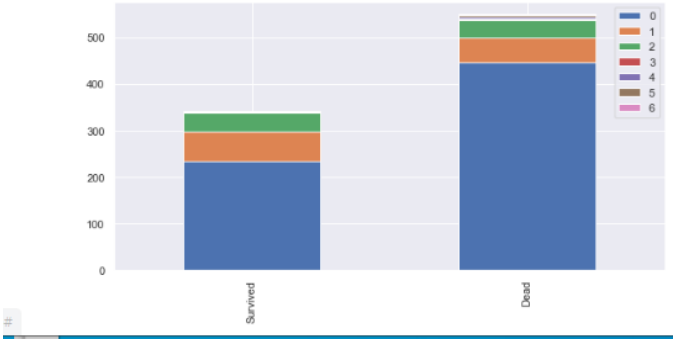

4. feature engineering

In [16]:
```
# 3. feature engineering
# train, test data 결측치 파악
# age와 cabin 속성에 결측값이 많이 나온것을 확인할 수 있다.
# train은 Embarked에서 2개의 결측값이 나왔다.
# test는 Fare에서 1개의 결측값이 나왔다.

print(train.isnull().sum())
print('----------------------')
print(test.isnull().sum())
```

```
PassengerId      0
Survived         0
Pclass           0
Name             0
Sex              0
Age            177
SibSp            0
Parch            0
Ticket           0
Fare             0
Cabin          687
Embarked         2
dtype: int64
----------------------
PassengerId      0
Pclass           0
Name             0
Sex              0
Age             86
SibSp            0
Parch            0
Ticket           0
Fare             1
Cabin          327
Embarked         0
dtype: int64
```

(1) 'Embarked'

In [17]:
```
# 1) Embarked
# 결측치 채우기

train['Embarked'].fillna('S', inplace=True)
train['Embarked'].isnull().sum()
```

Out[17]: 0

In [18]:
```
# train, test data의 Embarked에 대해서 범주형 변수를 0 또는 1 값을 가지는 새로운 feature로 바꾼다.
# one-hot-encoding 진행

train = pd.get_dummies(data=train, columns=['Embarked'],prefix='Em')
train.head()
```

Out[18]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Em_C	Em_Q	Em_S
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	0	0	1
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	1	0	0
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	0	0	1
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	0	0	1
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	0	0	1

In [19]:
```
test = pd.get_dummies(data=test, columns=['Embarked'],prefix='Em')
test.head()
```

Out[19]:

	PassengerId	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Em_C	Em_Q	Em_S
0	892	3	Kelly, Mr. James	male	34.5	0	0	330911	7.8292	NaN	0	1	0
1	893	3	Wilkes, Mrs. James (Ellen Needs)	female	47.0	1	0	363272	7.0000	NaN	0	0	1
2	894	2	Myles, Mr. Thomas Francis	male	62.0	0	0	240276	9.6875	NaN	0	1	0
3	895	3	Wirz, Mr. Albert	male	27.0	0	0	315154	8.6625	NaN	0	0	1
4	896	3	Hirvonen, Mrs. Alexander (Helga E Lindqvist)	female	22.0	1	1	3101298	12.2875	NaN	0	0	1

(2) 'Sex'

In [20]:
```
# 2) Sex
#  train, test data의 Sex에 대해서 범주형 변수를 0 또는 1 값을 가지는 새로운 feature로 바꾼다.
# one-hot-encoding 진행

train = pd.get_dummies(data=train, columns=['Sex'], prefix='Sex')
train.head()
```

Out[20]:

	PassengerId	Survived	Pclass	Name	Age	SibSp	Parch	Ticket	Fare	Cabin	Em_C	Em_Q	Em_S	Sex_female	Sex_male
0	1	0	3	Braund, Mr. Owen Harris	22.0	1	0	A/5 21171	7.2500	NaN	0	0	1	0	1
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	38.0	1	0	PC 17599	71.2833	C85	1	0	0	1	0
2	3	1	3	Heikkinen, Miss. Laina	26.0	0	0	STON/O2. 3101282	7.9250	NaN	0	0	1	1	0
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	35.0	1	0	113803	53.1000	C123	0	0	1	1	0
4	5	0	3	Allen, Mr. William Henry	35.0	0	0	373450	8.0500	NaN	0	0	1	0	1

In [21]:
```
test = pd.get_dummies(data=test, columns=['Sex'],prefix='Sex')
test.head()
```

Out[21]:

	PassengerId	Pclass	Name	Age	SibSp	Parch	Ticket	Fare	Cabin	Em_C	Em_Q	Em_S	Sex_female	Sex_male
0	892	3	Kelly, Mr. James	34.5	0	0	330911	7.8292	NaN	0	1	0	0	1
1	893	3	Wilkes, Mrs. James (Ellen Needs)	47.0	1	0	363272	7.0000	NaN	0	0	1	1	0
2	894	2	Myles, Mr. Thomas Francis	62.0	0	0	240276	9.6875	NaN	0	1	0	0	1
3	895	3	Wirz, Mr. Albert	27.0	0	0	315154	8.6625	NaN	0	0	1	0	1
4	896	3	Hirvonen, Mrs. Alexander (Helga E Lindqvist)	22.0	1	1	3101298	12.2875	NaN	0	0	1	1	0

(3) 'Pclass'

In [22]:
```
# 3) Pclass
#  train, test datad의 Pclass에 대해서 범주형 변수를 0 또는 1 값을 가지는 새로운 feature로 바꾼다.
# one-hot-encoding 진행

train = pd.get_dummies(data=train, columns=['Pclass'], prefix='Pclass')
train.head()
```

Out[22]:

	PassengerId	Survived	Name	Age	SibSp	Parch	Ticket	Fare	Cabin	Em_C	Em_Q	Em_S	Sex_female	Sex_male	Pclass_1	Pclass_2	Pcla
0	1	0	Braund, Mr. Owen Harris	22.0	1	0	A/5 21171	7.2500	NaN	0	0	1	0	1	0	0	
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	38.0	1	0	PC 17599	71.2833	C85	1	0	0	1	0	1	0	
2	3	1	Heikkinen, Miss. Laina	26.0	0	0	STON/O2. 3101282	7.9250	NaN	0	0	1	1	0	0	0	
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	35.0	1	0	113803	53.1000	C123	0	0	1	1	0	1	0	
4	5	0	Allen, Mr. William Henry	35.0	0	0	373450	8.0500	NaN	0	0	1	0	1	0	0	

In [23]:
```
test = pd.get_dummies(data=test, columns=['Pclass'], prefix='Pclass')
test.head()
```

Out[23]:

	PassengerId	Name	Age	SibSp	Parch	Ticket	Fare	Cabin	Em_C	Em_Q	Em_S	Sex_female	Sex_male	Pclass_1	Pclass_2	Pclass_3
0	892	Kelly, Mr. James	34.5	0	0	330911	7.8292	NaN	0	1	0	0	1	0	0	1
1	893	Wilkes, Mrs. James (Ellen Needs)	47.0	1	0	363272	7.0000	NaN	0	0	1	1	0	0	0	1
2	894	Myles, Mr. Thomas Francis	62.0	0	0	240276	9.6875	NaN	0	1	0	0	1	0	1	0
3	895	Wirz, Mr. Albert	27.0	0	0	315154	8.6625	NaN	0	0	1	0	1	0	0	1
		Hirvonen, Mrs.														

(4) 'Name'

In [24]:
```
# 4) Name
# Name이 너무 다양하게 존재한다. 따라서 Name의 middle에 있는 호칭만 추출한다.
for data in [train, test]:
    data['Rename']=''
    name =[]
    i = re.compile('([A-Za-z]+)#.')
    for value in data['Name']:
        name.append(i.search(value).group())
    data['Rename'] = name
```

In [25]:
```
# 재처리한 이름의 항목을 확인한다.

print(train['Rename'].value_counts())
print("============================")
print(test['Rename'].value_counts())
```

```
Mr.          517
Miss.        182
Mrs.         125
Master.       40
Dr.            7
Rev.           6
Col.           2
Mlle.          2
Major.         2
Sir.           1
Countess.      1
Jonkheer.      1
Lady.          1
Capt.          1
Ms.            1
Don.           1
Mme.           1
Name: Rename, dtype: int64
============================
Mr.         240
Miss.        78
Mrs.         72
Master.      21
Col.          2
Rev.          2
Dona.         1
Ms.           1
Dr.           1
Name: Rename, dtype: int64
```

In [26]:
```
# 당시 시대를 보았을 때, Major,Capt과 Sir은 남자임을 추측할 수 있어서 Mr로 대체한다.
# Mlle, Ms는 Miss, Mme은 Mrs로 대체한다.
# 나머지 호칭은 모르겠으므로 unkonwn 으로 대체한다.

for data in [train, test] :
    data['Rename'].replace(['Capt.','Sir.','Major.'],'Mr',inplace=True)
    data['Rename'].replace(['Mlle.','Ms.'],'Miss', inplace=True)
    data['Rename'].replace('Mme.','Mrs.', inplace=True)
    data['Rename'].replace(['Dr.','Rev.','Col.','Jonkheer.','Don.','Lady.','Countess.','Dona.'],'unkonwn', inplace=True)
    data['Rename'].replace(['Mr.','Miss.','Mrs.','Master.'],['Mr','Miss','Mrs','Master'],inplace=True)
```

In [27]:
```
# 재처리 재확인
print(train['Rename'].value_counts())
print("==============================")
print(test['Rename'].value_counts())
```

```
Mr         521
Miss       185
Mrs        126
Master      40
unkonwn     19
Name: Rename, dtype: int64
==============================
Mr         240
Miss        79
Mrs         72
Master      21
unkonwn      6
Name: Rename, dtype: int64
```

In [28]:
```
# Rename 속성을 이용할 것이므로 Name속성을 삭제한다.
train.drop('Name',axis=1, inplace=True)
test.drop('Name',axis=1, inplace=True)
```

In [29]:
```
#  train, test datad의 Rename에 대해서 범주형 변수를 0 또는 1 값을 가지는 새로운 feature로 바꾼다.
# one-hot-encoding 진행

train = pd.get_dummies(data=train, columns=['Rename'], prefix='Name')
train.head()
```

Out[29]:

	PassengerId	Survived	Age	SibSp	Parch	Ticket	Fare	Cabin	Em_C	Em_Q	...	Sex_female	Sex_male	Pclass_1	Pclass_2	Pclass_3	Name_Ma
0	1	0	22.0	1	0	A/5 21171	7.2500	NaN	0	0	...	0	1	0	0	1	
1	2	1	38.0	1	0	PC 17599	71.2833	C85	1	0	...	1	0	1	0	0	
2	3	1	26.0	0	0	STON/O2. 3101282	7.9250	NaN	0	0	...	1	0	0	0	1	
3	4	1	35.0	1	0	113803	53.1000	C123	0	0	...	1	0	1	0	0	
4	5	0	35.0	0	0	373450	8.0500	NaN	0	0	...	0	1	0	0	1	

5 rows × 21 columns

In [30]:
```
test = pd.get_dummies(data=test, columns=['Rename'], prefix='Name')
test.head()
```

Out[30]:

	PassengerId	Age	SibSp	Parch	Ticket	Fare	Cabin	Em_C	Em_Q	Em_S	Sex_female	Sex_male	Pclass_1	Pclass_2	Pclass_3	Name_Master	Na
0	892	34.5	0	0	330911	7.8292	NaN	0	1	0	0	1	0	0	1	0	
1	893	47.0	1	0	363272	7.0000	NaN	0	0	1	1	0	0	0	1	0	
2	894	62.0	0	0	240276	9.6875	NaN	0	1	0	0	1	0	1	0	0	
3	895	27.0	0	0	315154	8.6625	NaN	0	0	1	0	1	0	0	1	0	
4	896	22.0	1	1	3101298	12.2875	NaN	0	0	1	1	0	0	0	1	0	

(5) 'SibSp', 'Parch'

In [31]:
```
# 5) SibSp, Parch => Family size
# 위에서 보았듯이 형제 자매와 부모 자식이 없을 경우 생존율이 제일 높았다.
# 형제 자매 SibSp와 부모 자식 Parch를 합쳐서 가족 단위로 생각해준다.

for data in [train, test]:

    data.loc[data['SibSp']+data['Parch']==0,'Family'] = 'Solo'
    data.loc[(data['SibSp']+data['Parch']<=3)&(data['SibSp']+data['Parch']>0),'Family'] = 'Nuclear'
    data.loc[data['SibSp']+data['Parch']>3,'Family'] = 'Big'
```

In [32]:
```
# Family 속성을 이용할 것이므로 SibSp, Parch속성을 삭제한다.
train.drop('SibSp',axis=1, inplace=True)
test.drop('SibSp',axis=1, inplace=True)
train.drop('Parch',axis=1, inplace=True)
test.drop('Parch',axis=1, inplace=True)
```

In [33]:
```
# train, test datad의 Family에 대해서 범주형 변수를 0 또는 1 값을 가지는 새로운 feature로 바꾼다.
# one-hot-encoding 진행

train = pd.get_dummies(data=train, columns=['Family'], prefix='Family')
train.head()
```

Out[33]:

m_Q	Em_S	Sex_female	...	Pclass_2	Pclass_3	Name_Master	Name_Miss	Name_Mr	Name_Mrs	Name_unkonwn	Family_Big	Family_Nuclear	Family_Solo
0	1	0	...	0	1	0	0	1	0	0	0	1	0
0	0	1	...	0	0	0	0	0	1	0	0	1	0
0	1	1	...	0	1	0	1	0	0	0	0	0	1
0	1	1	...	0	0	0	0	0	1	0	0	1	0
0	1	0	...	0	1	0	0	1	0	0	0	0	1

In [34]:
```
test = pd.get_dummies(data=test, columns=['Family'], prefix='Family')
test.head()
```

Out[34]:

S	Sex_female	Sex_male	...	Pclass_2	Pclass_3	Name_Master	Name_Miss	Name_Mr	Name_Mrs	Name_unkonwn	Family_Big	Family_Nuclear	Family_Solo
0	0	1	...	0	1	0	0	1	0	0	0	0	1
1	1	0	...	0	1	0	0	0	1	0	0	1	0
0	0	1	...	1	0	0	0	1	0	0	0	0	1
1	0	1	...	0	1	0	0	1	0	0	0	0	1
1	1	0	...	0	1	0	0	0	1	0	0	1	0

(6) 'Age'

In [40]:
```
# 8) Age
# Age 결측치 채우기 - 평균값으로 채운다

train['Age'].fillna(train['Age'].median(), inplace=True)
test['Age'].fillna(test['Age'].median(), inplace=True)
```

In [41]:
```
# Age는 continous 자료다. 범위를 나눠서 group 번호로 다시 지정했다.

for data in [train, test]:

    data.loc[data['Age'] <= 16,'Age'] = 0
    data.loc[(data['Age'] > 16)&(data['Age']<=32),'Age'] = 1
    data.loc[(data['Age'] > 32)&(data['Age']<=48),'Age'] = 2
    data.loc[(data['Age'] > 48)&(data['Age']<=64),'Age'] = 3
    data.loc[data['Age'] > 64,'Age'] = 4

train['Age']= train['Age'].astype(int)
test['Age']= test['Age'].astype(int)
```

In [42]:
```
#  train, test datad의 Age에 대해서 범주형 변수를 0 또는 1 값을 가지는 새로운 feature로 바꾼다.
# one-hot-encoding 진행

train = pd.get_dummies(data=train, columns=['Age'], prefix='Age')
train.head()
```

Out[42]:

et_Letter	Em_C	Em_Q	Em_S	Sex_female	...	Name_Mrs	Name_unkonwn	Family_Big	Family_Nuclear	Family_Solo	Age_0	Age_1	Age_2	Age_3	Age_4
A	0	0	1	0	...	0	0	0	1	0	0	1	0	0	0
P	1	0	0	1	...	1	0	0	1	0	0	0	1	0	0
S	0	0	1	1	...	0	0	0	0	1	0	1	0	0	0
1	0	0	1	1	...	1	0	0	1	0	0	0	1	0	0
3	0	0	1	0	...	0	0	0	0	1	0	0	1	0	0

In [43]:
```
test = pd.get_dummies(data=test, columns=['Age'], prefix='Age')
test.head()
```

Out[43]:

_Q	Em_S	Sex_female	Sex_male	Pclass_1	...	Name_Mrs	Name_unkonwn	Family_Big	Family_Nuclear	Family_Solo	Age_0	Age_1	Age_2	Age_3	Age_4
1	0	0	1	0	...	0	0	0	0	1	0	0	1	0	0
0	1	1	0	0	...	1	0	0	1	0	0	0	1	0	0
1	0	0	1	0	...	0	0	0	0	1	0	0	0	1	0
0	1	0	1	0	...	0	0	0	0	1	0	1	0	0	0
0	1	1	0	0	...	1	0	0	1	0	0	1	0	0	0

(7) 'Fare'

In [44]:
```
# 7) Fare
# Fare 결측치 채우기
test['Fare'].fillna(test['Fare'].median(),inplace=True)
```

In [45]:
```
# Fare는 qcut을 이용해 4개의 범위로 나눠서 group을 지어 번호를 지정했다.

train['Fare']= pd.qcut(train['Fare'], 4, labels=[1,2,3,4])
test['Fare']= pd.qcut(test['Fare'], 4, labels=[1,2,3,4])
```

In [46]:
```
#  train, test datad의 Fare에 대해서 범주형 변수를 0 또는 1 값을 가지는 새로운 feature로 바꾼다.
# one-hot-encoding 진행

train = pd.get_dummies(data=train, columns=['Fare'], prefix='Fare')
train.head()
```

Out[46]:

t	Cabin	Ticket_Letter	Em_C	Em_Q	Em_S	Sex_female	Sex_male	...	Family_Solo	Age_0	Age_1	Age_2	Age_3	Age_4	Fare_1	Fare_2	Fare_3	Fare_4
l	NaN	A	0	0	1	0	1	...	0	0	1	0	0	0	1	0	0	0
)	C85	P	1	0	0	1	0	...	0	0	0	1	0	0	0	0	0	1
;	NaN	S	0	0	1	1	0	...	1	0	1	0	0	0	0	1	0	0
)	C123	1	0	0	1	1	0	...	0	0	0	1	0	0	0	0	0	1
)	NaN	3	0	0	1	0	1	...	1	0	0	1	0	0	0	1	0	0

In [47]:
```
test = pd.get_dummies(data=test, columns=['Fare'], prefix='Fare')
test.head()
```

Out[47]:

n	Em_C	Em_Q	Em_S	Sex_female	Sex_male	Pclass_1	Pclass_2	...	Family_Solo	Age_0	Age_1	Age_2	Age_3	Age_4	Fare_1	Fare_2	Fare_3	Fare_4
N	0	1	0	0	1	0	0	...	1	0	0	1	0	0	1	0	0	0
N	0	0	1	1	0	0	0	...	0	0	0	1	0	0	1	0	0	0

(8) 'Ticket'

In [48]:
```
# 8) Ticket
# '1', '2', '3', 'S', 'P', 'C', 'A' : 20개 이상을 가지고 있는 Ticket들은 각 Ticket의 앞 문자에 맞게 지정해준다.
# 'F', 'W', '4', '7', '6' : Low_ticket, 나머지는 Other_ticket으로 구분

 for data in [train, test]:
        data['Ticket_Letter'] = data['Ticket'].apply(lambda x: str(x)[0])
        data['Ticket_Letter'] = data['Ticket_Letter'].apply(lambda x: str(x))
        data['Ticket_Letter'] = np.where((data['Ticket_Letter']).isin(['1', '2', '3', 'S', 'P', 'C', 'A']), data['Ticket_Lett
                                 np.where((data['Ticket_Letter']).isin(['F','W', '4', '7', '6']),
                                          'Low_ticket', 'Other_ticket'))
```

In [49]:
```
# Ticket_Letter 속성을 이용할 것이므로 Ticket 속성을 삭제한다.
train.drop('Ticket',axis=1, inplace=True)
test.drop('Ticket',axis=1, inplace=True)
```

In [50]:
```
#  train, test datad의 Ticket_Letter에 대해서 범주형 변수를 0 또는 1 값을 가지는 새로운 feature로 바꾼다.
# one-hot-encoding 진행

train = pd.get_dummies(data=train, columns=['Ticket_Letter'], prefix='Ticket')
train.head()
```

Out[50]:

_female	Sex_male	Pclass_1	Pclass_2	...	Fare_4	Ticket_1	Ticket_2	Ticket_3	Ticket_A	Ticket_C	Ticket_Low_ticket	Ticket_Other_ticket	Ticket_P	Ticket_S
0	1	0	0	...	0	0	0	0	1	0	0	0	0	0
1	0	1	0	...	1	0	0	0	0	0	0	0	1	0
1	0	0	0	...	0	0	0	0	0	0	0	0	0	1
1	0	1	0	...	1	1	0	0	0	0	0	0	0	0
0	1	0	0	...	0	0	0	1	0	0	0	0	0	0

In [51]:
```
test = pd.get_dummies(data=test, columns=['Ticket_Letter'], prefix='Ticket')
test.head()
```

Out[51]:

ex_male	Pclass_1	Pclass_2	Pclass_3	...	Fare_4	Ticket_1	Ticket_2	Ticket_3	Ticket_A	Ticket_C	Ticket_Low_ticket	Ticket_Other_ticket	Ticket_P	Ticket_S
1	0	0	1	...	0	0	0	1	0	0	0	0	0	0
0	0	0	1	...	0	0	0	1	0	0	0	0	0	0
1	0	1	0		0	0	1	0	0	0	0	0	0	0

(9) 'Cabin'

In [52]:
```
# 9) Cabin, PassengerId
# Cabin 속성은 거의 70 %이상이 결측값이므로 해당 속성은 train, test에서 제외한다.
# PassengerId도 삭제한다.

train.drop('Cabin',axis=1, inplace=True)
test.drop('Cabin',axis=1, inplace=True)
train.drop('PassengerId',axis=1, inplace=True)
test.drop('PassengerId',axis=1, inplace=True)
```

5. 데이터 셋 분리

In [56]:
```
# 3. 데이터 셋 분리

x_train = train.drop('Survived',axis=1)
y_train = train['Survived']
x_train, x_test, y_train, y_test = train_test_split(x_train, y_train, test_size=0.3, random_state=42)
x_train.shape, y_train.shape, x_test.shape, y_test.shape
```

Out[56]: ((623, 34), (623,), (268, 34), (268,))

6. 모델 생성 및 성능 평가

In [64]:
```
# 4. 모델 생성
svc = SVC()
svc.fit(x_train, y_train)

print(svc.score(x_train, y_train))
print(svc.score(x_test, y_test))

test_pred = svc.predict(test)

submission = pd.DataFrame({
    "PassengerId": sub,
    "Survived" : test_pred
})

submission.to_csv('titanic_SVC.csv', index = False)
```

```
0.855537720706626
0.832089552238806
```

x_test로 predict시에는 85%의 정확도가 test set으로 predict시에는 83%의 정확도가 나왔습니다.

Kaggle score는 81%가 나왔습니다.

7. 개인 생각

- Ada boost Classifier 같은 경우는 x_test로 predict시에는 99%의 정확도가 test set으로 predict시에는 80%의 정확도가 나왔습니다. Kaggle score에는 78%의 정확도로 나온 것을 보아 overfitting이 되지 않았나 의심이 됩니다.

- SVC model과 Random Forest Classifier을 이용했을 때, 정확도가 81%로 가장 높았습니다.

- Random Forest Classifier, Ada boost Classifier, SVC model을 Voting classifier로 ensemble을 했을 경우에 78%로 오히려 Random Forest Classifier 경우보다 더 낮게 나왔습니다.

- 'Age'와 'Fare'와 같은 continuous형 자료에 대해서 처음에는 grouping을 하지 않고 숫자 그대로 학습을 시켰습니다. 그 때는 score가 80%였는데, 이를 qcut을 이용해 grouping을 하고 categorical형 자료를 one-hot encoding 진행 시, score가 81%로 나왔습니다. 이를 통해서, 학습 모델로 classifier를 이용할 때는 가능한 모든 속성이 one-hot encoding이 되어 있는 것이 정확도를 높인다고 생각합니다.

- 'Age' 속성의 결측 값을 채워 넣을 때, train과 test data set에 대해서 따로 mean을 구해 채웠습니다. 이를 train, test data set으로 구분한 것이 아니라 train, test data를 합쳐서 mean값을 구해 결측 값을 채웠으면 결과가 바뀌었을 지 확인해보지 못한 것이 아쉽습니다.

- 'Cabin' 속성에 대해서는 결측 값이 많아 속성을 제외하게 학습을 시켰는데, 이 속성의 결측 값을 채워서 학습을 했다면 결과가 바뀔지 궁금합니다. 가능하다면, 이 속성에 대해서 engineering하는 방법을 찾아보고 싶습니다.